



| 300  
ЛЕТ СПбГУ

# Singular Value Decomposition (SVD) и Principal Component Analysis (PCA)

Студент 1 курса

**Глухов Кирилл Дмитриевич**

26.M11-пу 2026 / 2027

С точки зрения математики, собственные числа и собственные векторы позволяют определять главные компоненты информации, то есть направления, вдоль которых данные имеют наибольшую дисперсию. Собственные числа позволяют определить значимость компонента, а собственные векторы задают направление компоненты. Мы можем определить важность компонент на основе значения собственных чисел и отбросить члены с малыми значениями  $\alpha$ . Тем самым можно уменьшить размерность и шум данных, незначительно снижая точность предсказаний.

$$A = \alpha_1 u_1 v_1^T + \alpha_2 u_2 v_2^T + \dots + \alpha_n u_n v_n^T$$

*eigenvectors of  $AA^T$*

*square root of eigenvalues of  $AA^T$*

*eigenvectors of  $A^T A$*

*can be ignored if it get too small*

## Характеристический полином

$$\det(A - \lambda \mathbf{I}) = \begin{vmatrix} a_{11} - \lambda & a_{12} \\ a_{21} & a_{22} - \lambda \end{vmatrix} =$$
$$= \lambda^2 - (a_{11} + a_{22})\lambda + (a_{11}a_{22} - a_{12}a_{21});$$

## Собственное число (eigenvalue)

$$\det(A - \lambda \mathbf{I}) = 0$$

# Пример

$$\det(A - \lambda I) = 0$$

$$\begin{vmatrix} 1 - \lambda & -3 & 3 \\ 3 & -5 - \lambda & 3 \\ 6 & -6 & 4 - \lambda \end{vmatrix} = 0$$

$$A = \begin{bmatrix} 1 & -3 & 3 \\ 3 & -5 & 3 \\ 6 & -6 & 4 \end{bmatrix}$$

$$(1 - \lambda) \begin{vmatrix} -5 - \lambda & 3 \\ -6 & 4 - \lambda \end{vmatrix} - (-3) \begin{vmatrix} 3 & 3 \\ 6 & 4 - \lambda \end{vmatrix} + 3 \begin{vmatrix} 3 & -5 - \lambda \\ 6 & -6 \end{vmatrix} = 0$$

$$16 + 12\lambda - \lambda^3 = 0$$

$$\lambda^3 - 12\lambda - 16 = 0$$

$$\text{when } \lambda = 4, \lambda^3 - 12\lambda - 16 = 0$$

$$\text{So } \lambda^3 - 12\lambda - 16 = (\lambda - 4)(\lambda^2 + 4\lambda + 4) = 0$$

By solving the root, the eigenvalues are 4, -2.

$$A - 4I = \begin{vmatrix} -3 & -3 & 3 \\ 3 & -9 & 3 \\ 6 & -6 & 0 \end{vmatrix}$$

Doing row reduction to solve the linear equation  $(A - \lambda I)v = 0$

$$\left| \begin{array}{ccc|c} -3 & -3 & 3 & 0 \\ 3 & -9 & 3 & 0 \\ 6 & -6 & 0 & 0 \end{array} \right|$$

Appending 0

Perform  $R_1 = -\frac{1}{3}R_1$

$$\left| \begin{array}{ccc|c} 1 & 1 & -1 & 0 \\ 3 & -9 & 3 & 0 \\ 6 & -6 & 0 & 0 \end{array} \right|$$

Perform row subtraction/multiplication:

$$\left| \begin{array}{ccc|c} 1 & 1 & -1 & 0 \\ 0 & -12 & 6 & 0 \\ 0 & -12 & 6 & 0 \end{array} \right|$$

After many more reductions:

$$\left| \begin{array}{ccc|c} 1 & 0 & -1/2 & 0 \\ 0 & 1 & -1/2 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right|$$

$$\begin{cases} x_1 - \frac{1}{2}x_3 = 0 \\ x_2 - \frac{1}{2}x_3 = 0 \end{cases}$$

**Собственный вектор  
(Eigenvector)**

$$\begin{bmatrix} 1/2 \\ 1/2 \\ 1 \end{bmatrix}$$

$$A + 2I = \begin{vmatrix} 3 & -3 & 3 \\ 3 & -3 & 3 \\ 6 & -46 & 6 \end{vmatrix}$$

$$\begin{cases} x_1 - x_2 + x_3 = 0 \end{cases}$$

$$\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

## Собственные векторы

$$\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & -3 & 3 \\ 3 & -5 & 3 \\ 6 & -6 & 4 \end{bmatrix}$$

## Собственные числа

$$\lambda_1 = 4$$

$$\lambda_2 = -2$$

$$\lambda_3 = -2$$

## Собственный векторы

$$\begin{bmatrix} 1/2 \\ 1/2 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

# Диагонализуемость. Квадратные матрицы весов.

Пусть матрица  $A$  имеет два собственных числа и два собственных вектора:

$$Av_1 = \lambda_1 v_1$$

$$Av_2 = \lambda_2 v_2$$

$$A \begin{bmatrix} v_1 & v_2 \end{bmatrix} = \begin{bmatrix} \lambda_1 v_1 & \lambda_2 v_2 \end{bmatrix} = \begin{bmatrix} v_1 & v_2 \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$$

$$A = \begin{bmatrix} v_1 & v_2 \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \begin{bmatrix} v_1 & v_2 \end{bmatrix}^{-1}$$

# Диагонализуемость. Квадратные матрицы весов.

Случай 3 собственных чисел:

$$A = \begin{bmatrix} | & | & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \mathbf{v}_3 \\ | & | & | \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{bmatrix} \begin{bmatrix} | & | & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \mathbf{v}_3 \\ | & | & | \end{bmatrix}^{-1}$$

square matrix

the inverse exists only if  
eigenvectors are linearly independent

Многомерный случай:

$$\begin{aligned} V^{-1} A V &= \Lambda \\ A &= V \Lambda V^{-1} \\ A^k &= V \Lambda^k V^{-1} \end{aligned}$$

# Диагонализуемость. Неквадратные матрицы весов.


Рассмотрим матрицу  $A$  размерности  $m \times n$ , при умножении  $A$  на  $A^T$ , получаем матрицы  $A \times A^T$  и  $A^T \times A$  - симметричные, квадратные, положительно определенные матрицы, одинакового  $rank(r)$ . Так как матрицы симметричны, мы можем выбрать собственные вектора, так чтобы они были ортонормированны.

Пусть собственные векторы  $A \times A^T$ :  $u_i$

Пусть собственные векторы  $A^T \times A$ :  $v_i$

Собственные числа этих матриц положительно определены.

*Квадратный корень собственного числа называется сингулярным числом.*



The diagram illustrates the construction of orthogonal matrices  $U$  and  $V$  from the eigenvectors of  $A \times A^T$  and  $A^T \times A$  respectively. It shows the matrices  $U$  and  $V$  as collections of column vectors  $u_1, \dots, u_m$  and  $v_1, \dots, v_n$ . A red arrow points from these matrices to a box containing the identities  $U^T U = I$  and  $V^T V = I$ .

$$U = \begin{pmatrix} | & & | \\ u_1 & \cdots & u_m \\ | & & | \end{pmatrix} \quad V = \begin{pmatrix} | & & | \\ v_1 & \cdots & v_n \\ | & & | \end{pmatrix}$$
$$U^T U = I$$
$$V^T V = I$$

# Singular Value Decomposition (SVD)

Любую матрицу  $A$  можно разбить на части:

$$A_{m \times n} = U_{m \times m} S_{m \times n} V_{n \times n}^T$$

$$\begin{array}{c} \begin{array}{ccc} & A & \\ \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ \vdots & & \ddots & \\ x_{m1} & & & x_{mn} \end{pmatrix} & = & \begin{array}{ccc} U & S & V^T \\ \begin{pmatrix} u_{11} & \dots & u_{m1} \\ \vdots & \ddots & \\ u_{1m} & \dots & u_{mm} \end{pmatrix} & \begin{pmatrix} \sigma_1 & \dots & 0 \\ \vdots & \ddots & \\ 0 & \dots & \sigma_r & \dots & 0 \\ \vdots & & \ddots & \ddots & \\ 0 & \dots & 0 \end{pmatrix} & \begin{pmatrix} v_{11} & \dots & v_{1n} \\ \vdots & \ddots & \\ v_{n1} & \dots & v_{nn} \end{pmatrix} \end{array} \\ m \times n & & m \times m \quad m \times n \quad n \times n \end{array}\end{array}$$

$$S = \begin{pmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ & & & & \ddots & \\ & & & & & 0 \end{pmatrix}$$

$\sigma_2$ : singular value

Упорядочиваем сингулярные числа и сингулярные векторы в порядке убывания.

$$\begin{array}{c} \sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m \\ \left( \begin{array}{ccc} \boxed{\phantom{u_1}} & \dots & \boxed{\phantom{u_m}} \\ u_1 & \dots & u_m \end{array} \right) \end{array}$$

# Пример SVD

$$A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}$$

$$AA^T = \begin{pmatrix} 17 & 8 \\ 8 & 17 \end{pmatrix}$$

eigenvalues:  $\lambda_1 = 25, \lambda_2 = 9$

eigenvectors

$$u_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} \quad u_2 = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

$$A^T A = \begin{pmatrix} 13 & 12 & 2 \\ 12 & 13 & -2 \\ 2 & -2 & 8 \end{pmatrix}$$

eigenvalues:  $\lambda_1 = 25, \lambda_2 = 9, \lambda_3 = 0$

eigenvectors

$$v_1 = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{pmatrix} \quad v_2 = \begin{pmatrix} 1/\sqrt{18} \\ -1/\sqrt{18} \\ 4/\sqrt{18} \end{pmatrix} \quad v_3 = \begin{pmatrix} 2/3 \\ -2/3 \\ -1/3 \end{pmatrix}$$

$$A = USV^T = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{pmatrix} \begin{pmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} & 0 \\ 1/\sqrt{18} & -1/\sqrt{18} & 4/\sqrt{18} \\ 2/3 & -2/3 & -1/3 \end{pmatrix}$$

# Доказательство SVD

$$A = U S V^T$$

$$A^T = (U S V^T)^T = V S^T U^T = V S U^T$$

$$U^T U = I$$

$$V^T V = I$$

$$A^T A = V S U^T (U S V^T) = V S^2 V^T$$
$$A^T A V = V S^2$$

$$A' v = \lambda v$$

$$A^T A v_i = \sigma_i^2 v_i$$

$$A^T A V = V S^2$$

the matrix


contain all  
eigenvectors

contain all  
eigenvalues

# Principal Component Analysis (PCA)

Метод главных компонент — это статистическая процедура, использующая ортогональное преобразование для перевода набора наблюдений за (возможно, коррелирующими) переменными в набор значений линейно некоррелированных переменных, называемых главными компонентами, меньшей размерности.

Рассмотрим многомерное облако точек, которое представляет собой данные. Каждая точка соответствует одному наблюдению, а каждое измерение — одной из переменных. Главные компоненты задают оси в этом пространстве, вдоль которых данные варьируются наиболее существенно. Проекция — это процесс переноса исходных точек на эти новые оси.



# Вычисление PCA через SVD

$X$  ( $n \times p$ ) - матрица данных. Центрируем  $X$ :

$$X_c = X - \mathbf{1}\bar{x}^T$$

Вычисляем SVD.  $U$  ( $n \times n$ ),  $S$ -diag( $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ ),  $V$  ( $p \times p$ ):

$$X_c = USV^T$$

Ковариационную матрицу  $C$  вычисляем через:

$$C = \frac{1}{n-1} X_c^T X_c = \frac{1}{n-1} V S^T S V^T = V \frac{S^2}{n-1} V^T$$

Снижение размерности до  $k$  признаков:

$$\hat{X}_c = T_k V_k^T = U_k S_k V_k^T = \sum_{j=1}^k S_j u_j v_j^T, \quad \hat{X} = \hat{X}_c + \mathbf{1}\bar{x}^T$$

Доля объясненной дисперсии:

$$\text{EVR}_j = \frac{\lambda_j}{\sum_i \lambda_i} = \frac{\sigma_j^2}{\sum_i \sigma_i^2}$$

Накопленная доля объясненной дисперсии:

$$\text{CEVR}_k = \frac{\sum_{j=1}^k \sigma_j^2}{\sum_{i=1}^r \sigma_i^2}$$

# Используемые источники

1. [Характеристический полином, собственные числа, собственные векторы | Vmath](#)
2. [Machine Learning — Singular Value Decomposition \(SVD\) & Principal Component Analysis \(PCA\)](#)

# Спасибо за внимание